

MICROSOFT · 实操实验工作坊

在 Azure 上托管智能体

在 Azure 上运行有状态 AI 智能体的三种生产模式

A

Foundry Host Agent

B

AKS + agent-sandbox

C

ACA Sandbox

以三种方式部署同一个智能体 · 对比隔离性、缩容至零、身份认证与成本 · 约 135 分钟



今天的安排

六个简短模块 —— 一个共享基础、三个方案实验、一个总结

0

引言

10 分钟 · 背景与架构 —— 你在这里

2

方案 A —— Foundry Host Agent

30 分钟 · 托管式入门，使用 azd 部署

4

方案 C —— ACA Sandbox

20 分钟 · 无服务器，gVisor 操作系统级隔离

1

核心基础设施

30 分钟 · 部署一次 —— 三个方案共用

3

方案 B —— AKS + agent-sandbox

40 分钟 · Kata Container 微型虚拟机隔离

5

总结与决策指南

5 分钟 · 对比、成本建议与问答



开始之前

前置条件与环境检查 —— 趁讲解概念时补齐缺口



账户与访问权限

- Azure 订阅 —— Contributor 访问权限
- 模块 1 的角色分配需要 Owner 或 User Access Administrator
- 角色: Foundry User (用于托管智能体)
- 角色: Container Apps SandboxGroup Data Owner



需安装的工具

- Azure CLI —— 已完成 az login
- Azure Developer CLI (azd) + Foundry 扩展
- kubectl 与 Docker (用于方案 B)
- ACA 预览扩展 (containerapp --allow-preview)



最常见的拦路虎: 创建角色分配需要 Owner 或 User Access Administrator —— 仅有 Contributor 无法完成。请现在确认你的权限。



为什么在 Azure 上托管智能体？

生产级智能体是有状态服务 —— 而非无状态的 API 调用

演示级智能体很简单。生产级智能体必须能记忆、隔离、认证、治理，并在空闲时保持低成本。



隔离性

租户 / 用户边界



缩容至零

空闲时零成本



身份与认证

托管标识，无需密钥



治理与成本

统一网关，成本可预测

没有万能方案——企业与消费者的优先级各不相同。本工作坊 = 同一个智能体的三种模式。



什么是「托管智能体」？

本工作坊每个方案都遵守的约定



持久化上下文

跨多轮对话记住内容



托管标识认证

使用 Azure 标识向模型认证 —— 无静态密钥



缩容至零 + 恢复

空闲时休眠，下次请求时重新加载状态



所有 LLM 调用经由 APIM

每次模型调用都经过统一受治理的 AI Gateway

无论采用哪种托管技术，智能体对调用方的表现都一致。



两类目标场景

企业 vs. 消费者 —— 驱动每个设计决策的用户画像



ToB —— 企业级

商业 / 内部平台

- 强租户与部门隔离 + 审计
- Entra ID —— SSO、RBAC、条件访问
- 数据驻留、专用网络、合规
- 预留或可突发，容量可预测

安全 · 治理 · 可靠性



ToC —— 消费者

个人终端用户 / 小型团队

- 海量短生命周期会话
- 进程级或容器级隔离（更轻量）
- 社交登录（External ID / B2C）或 API 密钥
- 积极缩容至零，按用量付费

成本 · 速度 · 简单性



三种方案一览

一图看懂全天 —— 同一个智能体，三种托管方式



Foundry Host Agent

最适合
ToB 托管 · 最快上手

隔离方式
托管（按智能体）

GA



AKS + agent-sandbox

最适合
ToB 高安全

隔离方式
微型虚拟机（Kata）

GA



ACA Sandbox

最适合
ToC / ToB 长时运行

隔离方式
操作系统级（gVisor）

公共预览

改变的只是隔离与控制方式 —— Blob 状态和 APIM AI Gateway 在三种方案中保持不变。



一次部署：核心基础设施

模块 1 —— 三种方案共用的共享基础



共享平台

资源组

Blob 存储

APIM (Basic v2)

Key Vault

容器注册表

Entra 应用注册

用户分配的托管标识



Foundry 技术栈

Foundry 账户

项目 maf-agent-prj

gpt-5.4-mini

Defender for AI

2 项 RAI 策略

APIM AI gateway

一次部署：setup.sh → main.bicep → core.bicep · 模块 B 与 C 通过 deploymentSN 标签发现它 —— 复用，绝不重建。



状态模式

Azure Blob 是唯一可信来源 —— 这正是缩容至零免费的原因



新请求

从 Azure Blob 加载状态 (每个智能体一个 JSON)



活动会话

每次变更都写入 Blob (每一轮)



缩容至零

无需刷写 —— 状态已持久化



唯一可信来源：Azure Blob 存储。每个智能体在 agent-state 容器中存储 `<AGENT_ID>.json`。无 Redis / 热缓存。冷层 + 版本控制 = 廉价且可恢复。



安全：身份 + AI Gateway

任何地方都没有静态密钥 —— APIM 是唯一受治理的入口



范围：用户 → 智能体的认证今天不在讨论范围内。我们保护的是智能体 → 模型这一段。

路径 1 —— 所有方案

- 智能体生成 Entra ID 令牌
- → APIM AI API (validate-jwt)
- → APIM 使用其 UAMI 调用 LLM

路径 2 —— 仅方案 A

- 托管智能体 → 其 Foundry 项目
- (Foundry 分配的标识 / Foundry User)
- → APIM AI gateway → LLM

APIM = 校验 JWT、速率限制、令牌配额、日志记录，并隐藏 Foundry 端点。



方案 A —— Foundry Host Agent

ToB 托管 · 最快上手 · 同时使用路径 1 和路径 2


速览

- 完全托管的智能体运行时 (Azure AI Foundry)
- 使用 azd 部署 —— 无需搭建新基础设施
- 模型路由: 直连或经网关 (一个环境变量)
- 通过 APIM AI Gateway 运行于 gpt-5.4-mini
- 状态: GA · 最适合 ToB 托管

Solution A — Azure AI Foundry Host Agent

ToB Managed · fully managed agent runtime · uses BOTH Path 1 and Path 2

GA



架构 —— 参见图中图例



方案 B —— AKS + agent-sandbox

ToB 高安全 · Kata Container 微型虚拟机隔离 · 仅路径 1


速览

- 最强隔离 —— Kata Container 微型虚拟机
- AKS Pod Sandboxing (kata-vm-isolation)
- agent-sandbox 控制器：
Sandbox CRD
- 生命周期：暂停 / 恢复 / 休眠
- 状态：GA · 最适合 ToB 高安全

Solution B — AKS + agent-sandbox

ToB High-Security · Kata Container micro-VM isolation · Path 1 only

GA



架构 —— 参见图中图例



方案 C —— ACA Sandbox

ToC / ToB 长时运行 · gVisor 操作系统级隔离 · 仅路径 1 (公共预览)


速览

- 通过 gVisor 实现操作系统级隔离 —— 无需专用虚拟机
- 挂起 / 恢复 + 快照状态
- 复用模块 3 的容器镜像
- 每个智能体一个容器 · UAMI / Workload Identity
- 状态: 公共预览 · ToC / 长时运行

Solution C — ACA Sandbox

ToC / ToB Long-Running · OS-level gVisor isolation, no dedicated VM · Path 1 only

Public Preview



架构 —— 参见图中图例



选择合适的方案

没有绝对赢家 —— 根据你的运维需求匹配托管方式

A

为企业提供最快速上手方式？

Foundry Host Agent

B

追求最大控制权、微型虚拟机隔离、专用网络？

AKS + agent-sandbox

C

长时运行、强隔离、无服务器？

ACA Sandbox

→

一次性 / 不可信代码执行（代码解释器）？

ACA Dynamic Sessions

模块 5 中提供完整的横向对比 —— 隔离性、缩容至零、状态、Entra ID、APIM、运维复杂度与成本。



成本与生产环境加固

提前预览模块 5 —— 让实验落到生产语境中



成本抓手

- 空闲 30 分钟后缩容至零
- Blob 冷层 —— 便宜约 50%
- Blob 生命周期规则清理过期状态
- AKS Spot 节点池 —— 最高省 90% (B)
- 高流量场景使用 Azure OpenAI PTU
- agent-sandbox WarmPool 调优 (B)




生产环境加固

- 专用网络 (VNet 注入)
- Blob 版本控制 + 软删除
- 使用 Azure Policy 保证合规
- 监控 APIM 4xx / 5xx 告警
- 在 AKS 上启用 Defender for Containers
- BCDR: 验证状态可从 Blob 恢复

开始动手吧。

第一站 → 模块 1：部署共享基础。



- 每个模块：一条命令部署或有引导的手动步骤
- 所有脚本与 README 都归你所有
- 全程欢迎提问 —— 总计约 135 分钟

```
$ cd agenthost/module-01 && ./setup.sh
```